

케라스로 구현하는 딥러닝

ANN / DNN / CNN

강사 윤영주

yj.youn1103@gmail.com



INDEX

1. KERAS 설치
2. ANN
 - 1) 필기체를 구분하는 ANN 구현
 - 2) 결과 데이터를 예측하는 회귀 ANN 구현
3. DNN
 - 1) 필기체를 구분하는 DNN 구현
 - 2) 컬러 이미지를 분류하는 DNN 구현
4. CNN
 - 1) 필기체를 구분하는 CNN 구현
 - 2) 컬러 이미지를 분류하는 CNN 구현



1. KERAS 설치



01. KERAS 설치


- 텐서플로우 설치
- 케라스 설치
 - ✓ Pip install keras
 - ✓ Conda install keras

2. ANN



02. ANN

Artificial Neural Network



02. ANN

Artificial Neural Network

- 인공신경망(ANN)은 생체의 신경망을 흉내 낸 인공지능
- 모든 비선형 함수를 학습 가능
- 입력 / 은닉 / 출력 계층으로 구성. 각 계층은 여러 노드로 구성
- 은닉 계층은 한 개 이상 포함 가능
- ANN의 활용
 1. 분류 : 입력 정보를 클래스별로 분류하는 방식
 2. 회귀 : 입력 정보로 다른 값을 예측

02. ANN

Artificial Neural Network

▪ 분류 ANN

- 입력 정보를 바탕으로 해당 입력이 어느 클래스에 속하는지 결정
- 입력 계층은 필기체 숫자 그림을 받아들이고, 출력 계층은 분류한 결과를 출력
- 분류할 클래스 수만큼 출력 노드를 만드는 방법이 효과적
- 판별은 분류 클래스 노드 값을 비교하여 가장 큰 쪽을 선택하도록 구현

02. ANN

Artificial Neural Network

▪ 회귀 ANN

- 입력값으로부터 출력값을 직접 예측하는 방법
- 실제 데이터의 규칙을 잘 표현하는 함수를 찾는 것이 목표
- 직전으로 된 회귀함수 외에 곡선, 다차원 회귀함수를 찾기도 가능
- 학습에 사용하지 않은 정보로도 예측이 가능

집값을 예측한다 하면 수많은 집 정보를 이용해 학습한 후 임의의 집 정보로 시세 예측 가능

02. ANN

Artificial Neural Network

- ANN 구현 방법 및 단계

1. 인공지능 구현용 패키지 가져오기
2. 인공지능에 필요한 매개변수 설정
3. 인공지능 모델 구현
4. 학습과 성능 평가용 데이터 가져오기
5. 인공지능 학습 및 성능 평가
6. 인공지능 학습 결과 분석

02. 1) 필기체를 구분하는 분류 ANN 구현

- 분류 ANN은 클래스가 둘 이상인 데이터를 분류하는 인공지능 방법
- 분류 ANN을 위한 인공지능 모델 구현
- 구현 방법 및 단계

① 필요 모듈 불러오기

```
from keras import layers, models  
import tensorflow as tf
```

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 순서대로 입력 계층의 노드 수, 은닉 계층의 노드 수, 출력값이 가질 클래스 수, 출력 노드 수

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 입력 계층은 지정 노드 수 지정

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 은닉 계층 지정
- ✓ 은닉 계층의 입력은 입력 노드이므로 입력 노드 지정
- ✓ 활성화 함수 'relu' 지정 / $f(x) = \max(x, 0)$

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 출력 계층의 입력은 은닉 계층이므로 은닉 노드 지정
- ✓ 분류의 경우 출력 노드 활성화 함수로 소프트맥스 연산 사용

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 케라스는 컴파일을 수행해 타깃 플랫폼에 맞게 딥러닝 코드를 구성
- ✓ Loss는 손실함수 지정, optimizer은 최적화 함수 지정,
metrics는 성능 검증을 위해 정확도 측정

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

② 분산 방식 모델링을 포함하는 ANN 모델

```
def ANN_models_func(Nin, Nh, Nout):  
    x = layers.Input(shape=(Nin,))  
    h = layers.Activation('relu')(layers.Dense(Nh)(x))  
    y = layers.Activation('softmax')(layers.Dense(Nout)(h))  
    model = models.Model(x, y)  
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 모델은 입력과 출력을 지정

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ③ 연쇄 방식 모델링을 포함하는 ANN 모델

```
def ANN_seq_func(Nin, Nh, Nout):  
    model = models.Sequential()  
    model.add(layers.Dense(Nh, activation='relu', input_shape=(Nin,)))  
    model.add(layers.Dense(Nout, activation='softmax'))  
    model.compile(loss='categorical_crossentropy',  
                  optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 함수형 프로그래밍 방식 활용
- ✓ 분산 방식과 모델을 지정하는 부분만 다르고 상수 정의 및 설정 모델 컴파일 코드는 같음
- ✓ 분산 방식과 다르게 모델 먼저 설정

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ③ 연쇄 방식 모델링을 포함하는 ANN 모델

```
def ANN_seq_func(Nin, Nh, Nout):  
    model = models.Sequential()  
    model.add(layers.Dense(Nh, activation='relu', input_shape=(Nin,)))  
    model.add(layers.Dense(Nout, activation='softmax'))  
    model.compile(loss='categorical_crossentropy',  
                  optimizer='adam', metrics=['accuracy'])  
    return model
```

- ✓ 모델 구조 설정
- ✓ 첫번째 add 단계에서 입력과 은닉 계층 형태가 동시에 정해짐
- ✓ 연쇄 방식은 추가되는 계층을 간편하게 기술 가능

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ④ 분산 방식 모델링을 포함하는 객체지향형 ANN 모델

```
class ANN_models_class(models.Model):  
    def __init__(self, Nin, Nh, Nout):  
        # Prepare network layers and activate functions  
        hidden = layers.Dense(Nh)  
        output = layers.Dense(Nout)  
        relu = layers.Activation('relu')  
        softmax = layers.Activation('softmax')  
  
        # Connect network elements  
        x = layers.Input(shape=(Nin,))  
        h = relu(hidden(x))  
        y = softmax(output(h))  
  
        super().__init__(x, y)  
        self.compile(loss='categorical_crossentropy',  
                      optimizer='adam', metrics=['accuracy'])
```

- ✓ 코드의 재사용성을 높이기 위해 객체지향 방식으로 구현 가능
- ✓ 전문가가 만든 인공지능 모델을 객체로 불러 쉽게 활용할 수 있음
- ✓ 클래스를 만들고 models.Model로 특성 상속
- ✓ models.Model은 신경망에서 사용하는 학습, 예측, 평가와 같은 함수 제공
- ✓ 클래스 초기화

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ④ 분산 방식 모델링을 포함하는 객체지향형 ANN 모델

```
class ANN_models_class(models.Model):  
    def __init__(self, Nin, Nh, Nout):  
        # Prepare network layers and activate functions  
        hidden = layers.Dense(Nh)  
        output = layers.Dense(Nout)  
        relu = layers.Activation('relu')  
        softmax = layers.Activation('softmax')  
  
        # Connect network elements  
        x = layers.Input(shape=(Nin,))  
        h = relu(hidden(x))  
        y = softmax(output(h))  
  
        super().__init__(x, y)  
        self.compile(loss='categorical_crossentropy',  
                      optimizer='adam', metrics=['accuracy'])
```

- ✓ 은닉 계층과 출력 계층 정의
- ✓ 비선형성 Activation함수 정의
- ✓ 상속받은 상위 클래스 초기화 진행

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ⑤ 연쇄 방식 모델링을 포함하는 객체지향형 ANN 모델

```
class ANN_seq_class(models.Sequential):  
    def __init__(self, Nin, Nh, Nout):  
        super().__init__()  
        self.add(layers.Dense(Nh, activation='relu', input_shape=(Nin,)))  
        self.add(layers.Dense(Nout, activation='softmax'))  
        self.compile(loss='categorical_crossentropy',  
                      optimizer='adam', metrics=['accuracy'])
```

- ✓ 연쇄 방식은 객체지향 또는 클래스 없이 기본 형태로 구성 가능
- ✓ 앞의 계층에 새로운 계층을 계속 추가하는 형태
- ✓ 입력 계층을 별도로 정의하지 않고 은닉 계층부터 추가

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ⑥ 분류 ANN에 사용할 데이터 가져오기

- ✓ MNIST는 6만 건의 필기체 숫자를 모은 공개 데이터

```
import numpy as np
from keras import datasets # mnist
from keras.utils import np_utils # to_categorical
```


- ✓ 라이브러리 가져오기

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

⑥ 분류 ANN에 사용할 데이터 가져오기

```
def Data func():  
    (X_train, y_train), (X_test, y_test) = tf.keras.datasets.mnist.load_data()  
  
    Y_train = np_utils.to_categorical(y_train)  
    Y_test = np_utils.to_categorical(y_test)  
  
    L, H, W = X_train.shape  
    X_train = X_train.reshape(-1, W * H)  
    X_test = X_test.reshape(-1, W * H)  
  
    X_train = X_train / 255.0  
    X_test = X_test / 255.0  
  
    return (X_train, Y_train), (X_test, Y_test)
```



- ✓ 변수 저장
- ✓ 0부터 9까지 숫자로 구성된 출력값은 0과 1로 표현되는 이진법 벡터로 변환

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

⑥ 분류 ANN에 사용할 데이터 가져오기

```
def Data_func():  
    (X_train, y_train), (X_test, y_test) = tf.keras.datasets.mnist.load_data()  
  
    Y_train = np_utils.to_categorical(y_train)  
    Y_test = np_utils.to_categorical(y_test)  
  
    L, H, W = X_train.shape  
    X_train = X_train.reshape(-1, W * H)  
    X_test = X_test.reshape(-1, W * H)  
  
    X_train = X_train / 255.0  
    X_test = X_test / 255.0  
  
    return (X_train, Y_train), (X_test, Y_test)
```

- ✓ ANN 학습을 위해 벡터 이미지 형채로 바꿈
- ✓ -1은 행렬의 행을 자동 설정
- ✓ 0~225사이의 정수로 구성된 입력값을 255로 나눔

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ⑦ 분류 ANN 학습 결과의 그래프 구현

```
import matplotlib.pyplot as plt
```

- ✓ 패키지 불러오기

- ✓ 손실 함수 및 정확도 함수 설정

```
# from keraspp.skera import plot_loss
def plot_loss(history, title=None):
    if not isinstance(history, dict):
        history = history.history
    plt.plot(history['loss'])
    plt.plot(history['val_loss'])
    if title is not None:
        plt.title(title)
    plt.xlabel('Epoch')
    plt.ylabel('Loss')
    plt.legend(['Training', 'Validation'], loc=0)
```

```
# from keraspp.skera import plot_acc
def plot_acc(history, title=None):
    if not isinstance(history, dict):
        history = history.history
    plt.plot(history['accuracy'])
    plt.plot(history['val_accuracy'])
    if title is not None:
        plt.title(title)
    plt.xlabel('Epoch')
    plt.ylabel('Accuracy')
    plt.legend(['Training', 'Validation'], loc=0)
```

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ⑧ 분류 ANN 학습 및 성능 분석

- ✓ 파라미터 정의

```
Nin = 784  
Nh = 100  
number_of_class = 10  
Nout = number_of_class
```

- ✓ 생성해 두었던 모델 사용. 데이터 불러오기

```
# model = ANN_models_func(Nin, Nh, Nout)  
# model = ANN_seq_func(Nin, Nh, Nout)  
# model = ANN_models_class(Nin, Nh, Nout)  
model = ANN_seq_class(Nin, Nh, Nout)  
(X_train, Y_train), (X_test, Y_test) = Data_func()
```

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

- ⑧ 분류 ANN 학습 및 성능 분석

- ✓ Fit함수를 이용해 모델 학습 진행

```
history = model.fit(X_train, Y_train, epochs=5, batch_size=100, validation_split=0.2)
```

- ✓ 5회 학습 / 100개씩 나눠서 넣기 / 20% 성능 검증 활용

```
Epoch 1/5
480/480 [=====] - 2s 3ms/step - loss: 0.3895 - accuracy: 0.8934 - val_loss: 0.2178 - val_accuracy: 0.9408
Epoch 2/5
480/480 [=====] - 1s 3ms/step - loss: 0.1871 - accuracy: 0.9469 - val_loss: 0.1647 - val_accuracy: 0.9545
Epoch 3/5
480/480 [=====] - 1s 2ms/step - loss: 0.1398 - accuracy: 0.9597 - val_loss: 0.1380 - val_accuracy: 0.9617
Epoch 4/5
480/480 [=====] - 1s 3ms/step - loss: 0.1115 - accuracy: 0.9679 - val_loss: 0.1264 - val_accuracy: 0.9633
Epoch 5/5
480/480 [=====] - 1s 2ms/step - loss: 0.0926 - accuracy: 0.9731 - val_loss: 0.1132 - val_accuracy: 0.9674
```

02. 1) 필기체를 구분하는 분류 ANN 구현

- 구현 방법 및 단계

⑧ 분류 ANN 학습 및 성능 분석

✓ 학습에 사용되지 않은 test데이터로 성능 최종 평가



```
performace_test = model.evaluate(X_test, Y_test, batch_size=100)
print('Test Loss and Accuracy ->', performace_test)
```

```
100/100 [=====] - 0s 2ms/step - loss: 0.1091 - accuracy: 0.9676
Test Loss and Accuracy -> [0.109053835272789, 0.9675999879837036]
```

✓ 손실과 정확도 그래프 확인

```
import os
os.environ['KMP_DUPLICATE_LIB_OK']='True'
```

```
plot_loss(history)
plt.show()
plot_acc(history)
plt.show()
```



02. 2) 결과 데이터를 예측하는 회귀 ANN 구현

- 보스턴 집값 예측하는 회귀 ANN 구현
- 구현 방법 및 단계
 - ① 회귀 ANN 모델 구현

```
from keras import layers, models  
import tensorflow as tf
```

- ✓ 케라스 서브패키지인 layers와 models는 각각 계층을 구성하는 툴과 계층을 합쳐 하나의 모델로 만들어 줌

02. 2) 결과 데이터를 예측하는 회귀 ANN 구현

- 구현 방법 및 단계

- ① 회귀 ANN 모델 구현

```
class ANN(models.Model):  
    def init (self, Nin, Nh, Nout):  
        # Prepare network layers and activate functions  
        hidden = layers.Dense(Nh)  
        output = layers.Dense(Nout)  
        relu = layers.Activation('relu')  
  
        # Connect network elements  
        x = layers.Input(shape=(Nin,))  
        h = relu(hidden(x))  
        y = output(h)  
  
        super().__init__(x, y)  
        self.compile(loss='mse', optimizer='sgd')
```

- ✓ 신경망 계층 정의
- ✓ ANN 각 계층의 신호 연결 상황 정의

- ✓ 입력계층은 Nin 길이를 가지는 1차원 열 벡터
- ✓ 손실함수 mse는 평균자승오류 mean squared error
- ✓ 최적화는 sgd 사용

02. 2) 결과 데이터를 예측하는 회귀 ANN 구현

- 구현 방법 및 단계

- ② 학습 평가용 데이터 가져오기

```
from keras import datasets
from sklearn import preprocessing
```

✓ 패키지 불러오기

```
def Data_func():
    (X_train, y_train), (X_test, y_test) = tf.keras.datasets.boston_housing.load_data()
    scaler = preprocessing.MinMaxScaler()
    X_train = scaler.fit_transform(X_train)
    X_test = scaler.transform(X_test)
    return (X_train, y_train), (X_test, y_test)
```

✓ 데이터 불러오기

✓ 최소값과 최대값을 0과 1로 정규화

✓ X_train으로 학습과 변환을 한 뒤 X_test 변환데이터 불러오기

02. 2) 결과 데이터를 예측하는 회귀 ANN 구현

- 구현 방법 및 단계

③ 회귀 ANN 학습 결과 그래프

```
from keraspp.sklearn import plot_loss  
import matplotlib.pyplot as plt
```

- ✓ 앞서 02. 1)의 그래프 그대로 사용
- ✓ 해당 함수를 keraspp폴더 아래 keras.py 파일에 넣어두고 필요시 사용

02. 2) 결과 데이터를 예측하는 회귀 ANN 구현

- 구현 방법 및 단계

④ 회귀 ANN 학습 및 성능 분석

```
Nin = 13  
Nh = 5  
Nout = 1
```

✓ 출력층은 회귀를 통해 결과값을 직접 예측하기 때문에 1로 지정

```
model = ANN(Nin, Nh, Nout)  
(X_train, y_train), (X_test, y_test) = Data_func()  
history = model.fit(X_train, y_train, epochs=100,  
                    batch_size=100, validation_split=0.2, verbose=2)
```

✓ ANN 구현과 유사

```
performace_test = model.evaluate(X_test, y_test, batch_size=100)  
print('\nTest Loss -> {:.2f}'.format(performace_test))
```

✓ 성능 평가

```
plot_loss(history)  
plt.show()
```

02. 2) 결과 데이터를 예측하는 회귀 ANN 구현


- 구현 방법 및 단계

④ 회귀 ANN 학습 및 성능 분석

```
Epoch 1/100  
4/4 - 1s - loss: 489.8331 - val_loss: 107.5058 - 664ms/epoch - 166ms/step  
Epoch 2/100  
4/4 - 0s - loss: 90.5829 - val_loss: 80.5713 - 42ms/epoch - 10ms/step  
Epoch 3/100  
4/4 - 0s - loss: 73.8577 - val_loss: 83.5623 - 40ms/epoch - 10ms/step  
Epoch 4/100  
4/4 - 0s - loss: 62.7855 - val_loss: 65.5345 - 42ms/epoch - 10ms/step  
Epoch 5/100  
4/4 - 0s - loss: 54.8131 - val_loss: 60.7337 - 42ms/epoch - 10ms/step
```

```
Epoch 98/100  
4/4 - 0s - loss: 17.7832 - val_loss: 19.7744 - 37ms/epoch - 9ms/step  
Epoch 99/100  
4/4 - 0s - loss: 20.1491 - val_loss: 18.6146 - 38ms/epoch - 9ms/step  
Epoch 100/100  
4/4 - 0s - loss: 18.1204 - val_loss: 19.0067 - 39ms/epoch - 10ms/step  
2/2 [=====] - 0s 3ms/step - loss: 21.2105
```

Test Loss -> 21.21




3. DNN



03. DNN

Deep Neural Network



DNN의 구조

03. DNN

Deep Neural Network

- 심층신경망(DNN)은 은닉 계층을 많이 쌓아서 만든 인공지능 기술
- 주로 하나의 은닉 계층을 포함하는 ANN과 달리 수십, 수백개의 은닉 계층으로 구성
- 계층이 많아져 우수한 성능을 낼 수 있고 적용 분야도 다양
- 다수의 은닉 계층은 입력 신호를 더 정교하게 처리
- 과적합을 얼마나 방지하느냐에 따라 좋은 모델이 될 수 있음

03. DNN


Deep Neural Network

경사도 소실과 ReLU 활성화 함수


- DNN은 여러 은닉 계층으로 구성되어 신경망의 최적화 과정 시 경사도 소실 발생 가능
- 경사도 소실 문제를 극복하기 위해 ReLU함수 사용
- ReLU는 입력이 0보다 큰 구간에서 직선 함수이기 때문에 값이 커져도 경사도 구하기 가능

Activation Functions

Sigmoid
 $\sigma(x) = \frac{1}{1+e^{-x}}$




tanh
 $\tanh(x)$



ReLU
 $\max(0, x)$




Leaky ReLU
 $\max(0.1x, x)$




Maxout
 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU
 $\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$



Different Activation Functions and their Graphs



03. DNN

Deep Neural Network

- DNN 구현 방법 및 단계

1. 기본 매개변수 설정
2. 분류 DNN 모델 구현
3. 데이터 준비
4. DNN의 학습 및 성능 평가

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

① 기본 매개변수 설정

```
Nin = 784  
Nh_l = [100, 50]  
number_of_class = 10  
Nout = number_of_class
```

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

② DNN 모델 구현

```
from keras import layers, models
import tensorflow as tf
```

```
class DNN(models.Sequential):
```

✓ 연쇄방식으로 계층 기술

```
    def __init__(self, Nin, Nh_l, Nout):
```

```
        super().__init__()
```

```
        self.add(layers.Dense(Nh_l[0], activation='relu', input_shape=(Nin,), name='Hidden-1'))
```

```
        self.add(layers.Dense(Nh_l[1], activation='relu', name='Hidden-2'))
```

```
        self.add(layers.Dense(Nout, activation='softmax'))
```

```
        self.compile(loss='categorical_crossentropy',
                      optimizer='adam',
                      metrics=['accuracy'])
```

✓ 2개의 히든 계층 생성

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

② DNN 모델 구현

```
from keras import layers, models
import tensorflow as tf
```

```
class DNN(models.Sequential):
```

✓ 연쇄방식으로 계층 기술

```
    def __init__(self, Nin, Nh_l, Nout):
```

```
        super().__init__()
```

```
        self.add(layers.Dense(Nh_l[0], activation='relu', input_shape=(Nin,), name='Hidden-1'))
```

```
        self.add(layers.Dense(Nh_l[1], activation='relu', name='Hidden-2'))
```

```
        self.add(layers.Dense(Nout, activation='softmax'))
```

```
        self.compile(loss='categorical_crossentropy',
                      optimizer='adam',
                      metrics=['accuracy'])
```

✓ 2개의 히든 계층 생성

③ 데이터 준비는 ANN에서 사용할 데이터 가져오기와 같음

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

③ 데이터 준비

```
import numpy as np
from keras import datasets
from keras.utils import np_utils

def Data_func():
    (X_train, y_train), (X_test, y_test) = tf.keras.datasets.mnist.load_data()

    Y_train = np_utils.to_categorical(y_train)
    Y_test = np_utils.to_categorical(y_test)

    L, W, H = X_train.shape
    X_train = X_train.reshape(-1, W * H)
    X_test = X_test.reshape(-1, W * H)

    X_train = X_train / 255.0
    X_test = X_test / 255.0

    return (X_train, Y_train), (X_test, Y_test)
```

✓ ANN과 같음

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

④ 학습 및 성능 평가

```
import matplotlib.pyplot as plt
from keraspp.keras import plot_loss, plot_acc

model = DNN(Nin, Nh_l, Nout)
(X_train, Y_train), (X_test, Y_test) = Data_func()

history = model.fit(X_train, Y_train, epochs=5, batch_size=100, validation_split=0.2)
performace_test = model.evaluate(X_test, Y_test, batch_size=100)
print('Test Loss and Accuracy ->', performace_test)

plot_loss(history)
plt.show()
plot_acc(history)
plt.show()
```

✓ ANN과 같음

03. 1) 필기체를 구분하는 분류 DNN 구현

- 구현 방법 및 단계

- ④ 학습 및 성능 평가

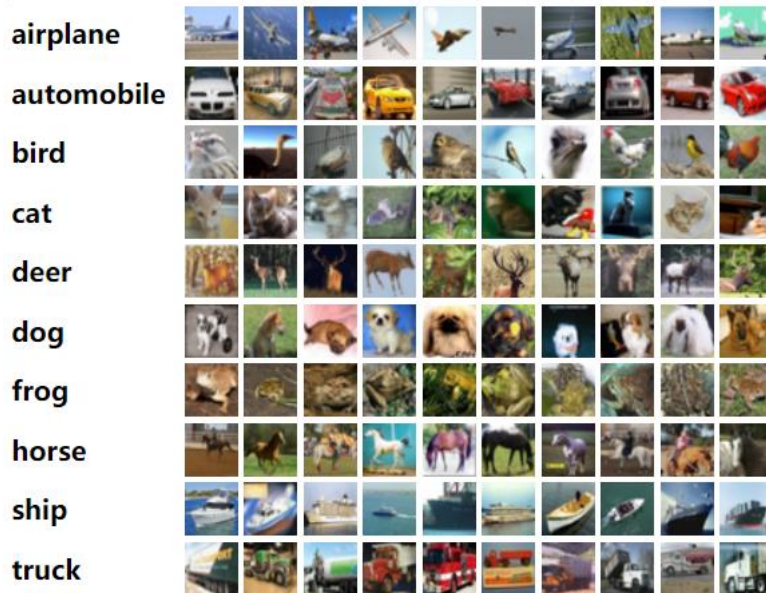
```
Epoch 1/5
480/480 [=====] - 2s 3ms/step - loss: 0.3785 - accuracy: 0.8919 - val_loss: 0.1934 - val_accuracy: 0.9457
Epoch 2/5
480/480 [=====] - 1s 3ms/step - loss: 0.1645 - accuracy: 0.9515 - val_loss: 0.1436 - val_accuracy: 0.9592
Epoch 3/5
480/480 [=====] - 1s 3ms/step - loss: 0.1164 - accuracy: 0.9660 - val_loss: 0.1222 - val_accuracy: 0.9653
Epoch 4/5
480/480 [=====] - 1s 3ms/step - loss: 0.0884 - accuracy: 0.9740 - val_loss: 0.1103 - val_accuracy: 0.9681
Epoch 5/5
480/480 [=====] - 1s 3ms/step - loss: 0.0704 - accuracy: 0.9789 - val_loss: 0.0975 - val_accuracy: 0.9720
100/100 [=====] - 0s 2ms/step - loss: 0.0924 - accuracy: 0.9715
Test Loss and Accuracy -> [0.09240478277206421, 0.9714999794960022]
```

- ✓ ANN과 거의 유사
- ✓ MNIST가 비교적 이미지가 간단해 성능 차이가 없으나 데이터가 많거나 복잡한 이미지에서는 일반적으로 DNN이 더 우수한 성능을 보임

03. 2) 컬러 이미지를 분류하는 DNN 구현

- 필기체보다 복잡도가 높은 컬러 이미지를 DNN으로 분류
- 사용할 데이터셋은 CIFAR-10

10가지 사물이 담긴 컬러 이미지로 총 6만장, $32 \times 32 \times 3$ 픽셀로 이루어져 있음



03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

① 데이터 가져오기

```
import numpy as np
from keras import datasets
from keras.utils import np_utils
import tensorflow as tf
```

✓ 패키지 가져오기

```
def Data_func():
    (X_train, y_train), (X_test, y_test) = tf.keras.datasets.cifar10.load_data()
```

```
Y_train = np_utils.to_categorical(y_train)
Y_test = np_utils.to_categorical(y_test)
```

```
L, W, H, C = X_train.shape
X_train = X_train.reshape(-1, W * H * C)
X_test = X_test.reshape(-1, W * H * C)
```

```
X_train = X_train / 255.0
X_test = X_test / 255.0
```

```
return (X_train, Y_train), (X_test, Y_test)
```

✓ 10가지 클래스로 구분된 2차원 배열로 변환

✓ 컬러 이미지 포함 4차원

03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

② DNN 모델링

```
from keras import layers, models

class DNN(models.Sequential):
    def __init__(self, Nin, Nh_l, Pd_l, Nout):
        super().__init__()

        self.add(layers.Dense(Nh_l[0], activation='relu',
                               input_shape=(Nin,), name='Hidden-1'))
        self.add(layers.Dropout(Pd_l[0]))
        self.add(layers.Dense(Nh_l[1], activation='relu',
                               name='Hidden-2'))
        self.add(layers.Dropout(Pd_l[1]))

        self.add(layers.Dense(Nout, activation='softmax'))

        self.compile(loss='categorical_crossentropy',
                      optimizer='adam',
                      metrics=['accuracy'])
```

✓ Dropout은 지정된 확률만큼 노드의 신호가 단절

03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

③ 학습 효과 분석

```
from keraspp.keras import plot_loss, plot_acc  
import matplotlib.pyplot as plt
```

- ✓ 효과 분석하는 코드 가져오기

03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

③ 학습 효과 분석

```
from keraspp.keras import plot_loss, plot_acc  
import matplotlib.pyplot as plt
```

- ✓ 효과 분석하는 코드 가져오기

03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

④ 학습 및 성능 평가

```
Pd_l=[0.0, 0.0]
Nh_l = [100, 50]
number_of_class = 10
Nout = number_of_class

(X_train, Y_train), (X_test, Y_test) = Data_func()
model = DNN(X_train.shape[1], Nh_l, Pd_l, Nout)
history = model.fit(X_train, Y_train, epochs=100, batch_size=100, validation_split=0.2)

performace_test = model.evaluate(X_test, Y_test, batch_size=100)
print('Test Loss and Accuracy ->', performace_test)

plot_acc(history)
plt.show()
plot_loss(history)
plt.show()
```

✓ 학습 진행 과정은 history 변수에 저장



03. 2) 컬러 이미지를 분류하는 DNN 구현

- 구현 방법 및 단계

④ 학습 및 성능 평가

```
Epoch 97/100
400/400 [=====] - 2s 4ms/step - loss: 1.1878 - accuracy: 0.5708 - val_loss: 1.5486 - val_accuracy: 0.4724
Epoch 98/100
400/400 [=====] - 2s 4ms/step - loss: 1.1857 - accuracy: 0.5730 - val_loss: 1.5094 - val_accuracy: 0.4805
Epoch 99/100
400/400 [=====] - 2s 4ms/step - loss: 1.1832 - accuracy: 0.5748 - val_loss: 1.5338 - val_accuracy: 0.4758
Epoch 100/100
400/400 [=====] - 2s 4ms/step - loss: 1.1860 - accuracy: 0.5729 - val_loss: 1.4946 - val_accuracy: 0.4814
100/100 [=====] - 0s 2ms/step - loss: 1.4676 - accuracy: 0.4901
Test Loss and Accuracy -> [1.46756112575531, 0.4900999963283539]
```

- ✓ 10가지 사물을 인공지능이 약 49%까지 분류할 수 있다는 의미
- ✓ 드롭아웃을 하지 않아서 학습데이터와 검증 데이터 간에 성능 차이가 큼
- ✓ 드롭아웃 설정값 조정하여 과적합 줄이기 가능




4. CNN



04. CNN

Convolutional Neural Network



CNN의 구조

04. CNN

Convolutional Neural Network

- 합성곱신경망(CNN)은 영상 처리에 많이 활용되는 합성곱을 이용하는 인공신경망 기술
- 합성곱을 이용해 가중치 수를 줄여 연산량을 줄이면서 이미지 처리를 효과적으로 함
- 이미지의 특징점을 효율적으로 찾을 수 있어 인공신경망 효능을 높일 수 있음
- CNN 원리
 - ✓ CNN은 합성곱 필터를 이용해 신경망 동작을 수행
 - ✓ 여러 작은 필터가 이미지 위를 돌아다니며 특징점을 찾아 합성곱 결과를 다음 계층으로 보냄
 - ✓ DNN 대비 적은 수의 가중치로 이미지 처리 효율적으로 가능

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

① 분류 CNN 모델링

```
import keras
from keras import models, layers
from keras import backend
import tensorflow as tf
```

- ✓ 서브 패키지 불러오기
- ✓ Models : 연쇄 방식 모델링 객체인 squential 사용
- ✓ Layers : Conv2D, Maxpooling2D, Flatten

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

① 분류 CNN 모델링

```
import keras
from keras import models, layers
from keras import backend
import tensorflow as tf
```

- ✓ 서브 패키지 불러오기
- ✓ Models : 연쇄 방식 모델링 객체인 squential 사용
- ✓ Layers : Conv2D, Maxpooling2D, Flatten
- ✓ Backend : 딥러닝 엔진 직접 제어

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

- ① 분류 CNN 모델링

```
class CNN(models.Sequential):  
    def __init__(self, input_shape, num_classes):  
        super().__init__()  
  
        self.add(layers.Conv2D(32, kernel_size=(3, 3),  
                                activation='relu',  
                                input_shape=input_shape))  
        self.add(layers.Conv2D(64, (3, 3), activation='relu'))  
        self.add(layers.MaxPooling2D(pool_size=(2, 2)))  
        self.add(layers.Dropout(0.25))  
        self.add(layers.Flatten())  
        self.add(layers.Dense(128, activation='relu'))  
        self.add(layers.Dropout(0.5))  
        self.add(layers.Dense(num_classes, activation='softmax'))  
  
        self.compile(loss=keras.losses.categorical_crossentropy,  
                    optimizer='rmsprop',  
                    metrics=['accuracy'])
```

- ✓ 첫 번째 은닉 계층 정의
- ✓ 3X3 커널 32개로 구성
- ✓ 최대 풀링을 수행해 인접한 2X2 셀을 묶어 가장 큰 값만 내보내는 부속 계층
- ✓ 드롭아웃 진행
- ✓ Flatten은 2차원 이미지를 1차원 벡터로 변환

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

② 분류 CNN을 위한 데이터 준비

```
from keras import datasets

class DATA():
    def __init__(self):
        num_classes = 10

        (x_train, y_train), (x_test, y_test) = tf.keras.datasets.mnist.load_data()
        img_rows, img_cols = x_train.shape[1:]

        if backend.image_data_format() == 'channels_first':
            x_train = x_train.reshape(x_train.shape[0], 1, img_rows, img_cols)
            x_test = x_test.reshape(x_test.shape[0], 1, img_rows, img_cols)
            input_shape = (1, img_rows, img_cols)
        else:
            x_train = x_train.reshape(x_train.shape[0], img_rows, img_cols, 1)
            x_test = x_test.reshape(x_test.shape[0], img_rows, img_cols, 1)
            input_shape = (img_rows, img_cols, 1)

        x_train = x_train.astype('float32')
        x_test = x_test.astype('float32')
        x_train /= 255
        x_test /= 255

        y_train = keras.utils.to_categorical(y_train, num_classes)
        y_test = keras.utils.to_categorical(y_test, num_classes)

        self.input_shape = input_shape
        self.num_classes = num_classes
        self.x_train, self.y_train = x_train, y_train
        self.x_test, self.y_test = x_test, y_test
```

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

- ② 분류 CNN을 위한 데이터 준비

```
(x_train, y_train), (x_test, y_test) = tf.keras.datasets.mnist.load_data()
```

- ✓ DNN과 다른 점 1) 이미지를 벡터화 하지 않고 그대로 사용 2) 흑백 이미지의 채널 정보를 처리하려면 추가적인 차원을 이미지 데이터에 포함해야 함

```
if backend.image_data_format() == 'channels_first':  
    x_train = x_train.reshape(x_train.shape[0], 1, img_rows, img_cols)  
    x_test = x_test.reshape(x_test.shape[0], 1, img_rows, img_cols)  
    input_shape = (1, img_rows, img_cols)  
else:  
    x_train = x_train.reshape(x_train.shape[0], img_rows, img_cols, 1)  
    x_test = x_test.reshape(x_test.shape[0], img_rows, img_cols, 1)  
    input_shape = (img_rows, img_cols, 1)
```

- ✓ 이미지 앞단에 채널 추가

- ✓ 맨 앞에 1로 채널 수 표시

- ✓ 맨 뒤에 1로 채널 수 표시

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

② 분류 CNN을 위한 데이터 준비

```
if backend.image_data_format() == 'channels_first':  
    x_train = x_train.reshape(x_train.shape[0], 1, img_rows, img_cols)  
    x_test = x_test.reshape(x_test.shape[0], 1, img_rows, img_cols)  
    input_shape = (1, img_rows, img_cols)  
else:  
    x_train = x_train.reshape(x_train.shape[0], img_rows, img_cols, 1)  
    x_test = x_test.reshape(x_test.shape[0], img_rows, img_cols, 1)  
    input_shape = (img_rows, img_cols, 1)
```

- ✓ 샘플 수, 채널 수, 이미지의 가로 길이, 이미지의 세로 길이로 구성
- ✓ DNN과 달리 이미지의 가로와 세로가 구분되어 다뤄짐

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN 학습 효과 분석

```
from keraspp.keras import plot_loss, plot_acc  
import matplotlib.pyplot as plt
```

- ✓ 그래프 그리는 기능 가져오기

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN 학습 및 성능 평가

```
batch_size = 128
epochs = 10

data = DATA()
model = CNN(data.input_shape, data.num_classes)

history = model.fit(data.x_train, data.y_train,
                    batch_size=batch_size,
                    epochs=epochs,
                    validation_split=0.2)

score = model.evaluate(data.x_test, data.y_test)
print()
print('Test loss:', score[0])
print('Test accuracy:', score[1])

plot_loss(history)
plt.show()
plot_acc(history)
plt.show()
```

- ✓ 준비된 데이터를 data 인스턴스에 넣어두고 모델을 model 인스턴스에 저장
- ✓ 20% 분리하여 검증 데이터로 사용
- ✓ 검증 데이터는 학습 데이터의 일부분이므로 평가 데이터와는 다름
- ✓ 데이터 평가

04. 1) 필기체를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN 학습 및 성능 평가

Epoch 9/10

375/375 [=====] - 25s 68ms/step - loss: 0.0422 - accuracy: 0.9881 - val_loss: 0.0407 - val_accuracy: 0.9896



Epoch 10/10

375/375 [=====] - 27s 73ms/step - loss: 0.0392 - accuracy: 0.9885 - val_loss: 0.0402 - val_accuracy: 0.9895

313/313 [=====] - 3s 10ms/step - loss: 0.0327 - accuracy: 0.9893

Test loss: 0.03266153112053871

Test accuracy: 0.989300012588501



04. 2) 컬러 이미지를 분류하는 CNN 구현

- CIFAR-10 컬러 이미지 분류하는 CNN 구현 방법 및 단계
 1. 분류 CNN 패키지 가져오기
 2. 분류 CNN 모델링
 3. 분류 CNN을 위한 데이터 준비
 4. 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스
 5. 분류 CNN의 수행

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

① 분류 CNN 패키지 가져오기

```
from sklearn import model_selection, metrics
from sklearn.preprocessing import MinMaxScaler
import tensorflow as tf
```

```
import numpy as np
import matplotlib.pyplot as plt
import os
```

```
from keras import backend as K
from keras.utils import np_utils
from keras.models import Model
from keras.layers import Input, Conv2D, MaxPooling2D, Flatten, Dense, Dropout
```

```
from keraspp import skeras
from keraspp import sfile
```

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

① 분류 CNN 패키지 가져오기

```
1 import datetime
2 import uuid
3 import os
4
5
6 def unique_filename(type='uuid'):
7     if type == 'datetime':
8         filename = datetime.datetime.now().strftime("%y%m%d_%H%M%S")
9     else: # type == "uuid"
10         filename = str(uuid.uuid4())
11     return filename
12
13
14 def makenewfold(prefix='output_', type='datetime'):
15     suffix = unique_filename('datetime')
16     foldname = 'output_' + suffix
17     os.makedirs(foldname)
18     return foldname
19
```

✓ Sfile.py

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

② 분류 CNN 모델링

- ✓ 사용할 인공지능망 모델은 LeNet

LeNet의 구조




Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

② 분류 CNN 모델링

2. 분류 CNN 모델링

```
class CNN(Model):  
    def __init__(self, nb_classes):  
        super(CNN, self).__init__()   
        self.nb_classes = nb_classes  
  
        self.conv2D_A = Conv2D(32, kernel_size=(3, 3), activation='relu')  
        self.conv2D_B = Conv2D(64, (3, 3), activation='relu')  
        self.maxPooling2D_A = MaxPooling2D(pool_size=(2, 2))  
        self.dropout_A = Dropout(0.25)  
        self.flatten = Flatten()  
  
        self.dense_A = Dense(128, activation='relu')  
        self.dropout_B = Dropout(0.5)  
        self.dense_B = Dense(nb_classes, activation='softmax', name='preds')  
  
    def call(self, x):  
        h = self.conv2D_A(x)  
        h = self.conv2D_B(h)  
        h = self.maxPooling2D_A(h)  
        h = self.dropout_A(h)  
        h = self.flatten(h)  
  
        h = self.dense_A(h)  
        h = self.dropout_B(h)  
  
        y = self.dense_B(h)  
  
        return y
```

✓ 모델에 사용될 구성 요소

✓ 모델 호출 시 사용되는 함수

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

② 분류 CNN 모델링

```
nb_classes = 10
model = CNN(nb_classes=nb_classes)
model.compile(loss='categorical_crossentropy',
              optimizer='adadelta', metrics=['accuracy'])
```

✓ 모델 사용 준비

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

3. 분류 CNN을 위한 데이터 준비

```
class DataSet:
    def __init__(self, X, y, nb_classes, scaling=True,
                 test_size=0.2, random_state=0):
        self.X = X
        self.add_channels()
        X = self.X
```

- ✓ 주어진 데이터를 머신러닝에 사용하기 적합하도록 조정하는 기능인 DataSet 클래스를 만듦
- ✓ 데이터 선언하고 초기화 진행
- ✓ 입력값인 X를 멤버 변수로 지정한 후 채널 정보 추가

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
# the data, shuffled and split between train and test sets
X_train, X_test, y_train, y_test = model_selection.train_test_split(
    X, y, test_size=0.2, random_state=random_state)

print(X_train.shape, y_train.shape)

X_train = X_train.astype('float32')
X_test = X_test.astype('float32')
```

- ✓ 데이터 세팅
- ✓ 80% 학습 데이터 지정
- ✓ 이미지 데이터가 정수인 경우가 있으니 32비트 규격의 실수로 바꾸어 줌

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

3. 분류 CNN을 위한 데이터 준비

```
class DataSet:
    def __init__(self, X, y, nb_classes, scaling=True,
                 test_size=0.2, random_state=0):
        self.X = X
        self.add_channels()
        X = self.X
```

- ✓ 주어진 데이터를 머신러닝에 사용하기 적합하도록 조정하는 기능인 DataSet 클래스를 만들
- ✓ 데이터 선언하고 초기화 진행
- ✓ 입력값인 X를 멤버 변수로 지정한 후 채널 정보 추가

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
if scaling:
    # scaling to have (0, 1) for each feature (each pixel)
    scaler = MinMaxScaler()
    n = X_train.shape[0]
    X_train = scaler.fit_transform(
        X_train.reshape(n, -1)).reshape(X_train.shape)
    n = X_test.shape[0]
    X_test = scaler.transform(
        X_test.reshape(n, -1)).reshape(X_test.shape)
    self.scaler = scaler
```

```
print('X_train shape:', X_train.shape)
print(X_train.shape[0], 'train samples')
print(X_test.shape[0], 'test samples')
```

- ✓ 스케일링 실시
- ✓ 스케일링 기준은 학습 데이터인 X_train이어야만 함
- ✓ 출력값은 원핫 인코딩을 이용해 정수값을 이진 벡터로 바꾸어 줌

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
# convert class vectors to binary class matrices  
Y_train = np_utils.to_categorical(y_train, nb_classes)  
Y_test = np_utils.to_categorical(y_test, nb_classes)
```

```
self.X_train, self.X_test = X_train, X_test  
self.Y_train, self.Y_test = Y_train, Y_test  
self.y_train, self.y_test = y_train, y_test
```

- ✓ Nb_classes는 클래스 수. 클래스 수만큼 이진 원소를 가진 벡터로 바꾸어 줌
- ✓ 학습과 검증에 사용할 데이터를 멤버 변수로 등록

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
def add_channels(self):
    X = self.X

    if len(X.shape) == 3:
        N, img_rows, img_cols = X.shape

        if K.image_dim_ordering() == 'th':
            X = X.reshape(X.shape[0], 1, img_rows, img_cols)
            input_shape = (1, img_rows, img_cols)
        else:
            X = X.reshape(X.shape[0], img_rows, img_cols, 1)
            input_shape = (img_rows, img_cols, 1)
    else:
        input_shape = X.shape[1:] # channel is already included.

    self.X = X
    self.input_shape = input_shape
```

- ✓ 흑백 이미지인지 검사
- ✓ 'th' 시애노 방식의 데이터 포맷을 사용한다면 채널 정보를 길이정보 바로 다음인 두 번째 차원에 삽입하고 텐서플로 방식의 포맷인 경우 맨 마지막에 넣어줌

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
from keras import datasets
(X, y), (x_test, y_test) = tf.keras.datasets.cifar10.load_data()
nb_classes = 10
data = DataSet(X, y, nb_classes)
print('data.input_shape', data.input_shape)
```

```
(40000, 32, 32, 3) (40000, 1)
X_train shape: (40000, 32, 32, 3)
40000 train samples
10000 test samples
data.input_shape (32, 32, 3)
```

✓ DataSet클래스는 다음과 같이 사용 가능

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

③ 분류 CNN을 위한 데이터 준비

```
epochs=2  
batch_size=128  
verbose=1  
history = model.fit(data.X_train, data.Y_train,  
                    batch_size=batch_size, epochs=epochs,  
                    verbose=verbose,  
                    validation_data=(data.X_test, data.Y_test))
```

- ✓ 만들어진 데이터를 이용해 앞서 정의한 CNN 모델로 간단하게 학습하는 방법

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

④ 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

4. 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

```
class Machine():  
    def __init__(self, X, y, nb_classes=2, fig=True):  
        self.nb_classes = nb_classes  
        self.set_data(X, y)  
        self.set_model()  
        self.fig = fig  
  
    def set_data(self, X, y):  
        nb_classes = self.nb_classes  
        self.data = DataSet(X, y, nb_classes)  
        print('data.input_shape', self.data.input_shape)
```

- ✓ 학습 및 성능 평가를 쉽게 수행할 수 있는 상위 개념 클래스
- ✓ 클래스 초기화
- ✓ 데이터 설정 함수

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

④ 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

```
def set_model(self):
    nb_classes = self.nb_classes
    data = self.data
    self.model = CNN(nb_classes=nb_classes)
    self.model.compile(loss='categorical_crossentropy',
                       optimizer='adadelta', metrics=['accuracy'])

def fit(self, epochs=10, batch_size=128, verbose=1):
    data = self.data
    model = self.model

    history = model.fit(data.X_train, data.Y_train,
                        batch_size=batch_size, epochs=epochs,
                        verbose=verbose,
                        validation_data=(data.X_test, data.Y_test))

    return history
```

✓ 모델 설정 함수

✓ 학습 진행 멤버 함수

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

④ 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

```
def run(self, epochs=100, batch_size=128, verbose=1):
    data = self.data
    model = self.model
    fig = self.fig

    history = self.fit(epochs=epochs,
                      batch_size=batch_size, verbose=verbose)

    score = model.evaluate(data.X_test, data.Y_test, verbose=0)

    print('Confusion matrix')
    Y_test_pred = model.predict(data.X_test, verbose=0)
    y_test_pred = np.argmax(Y_test_pred, axis=1)
    print(metrics.confusion_matrix(data.y_test, y_test_pred))

    print('Test score:', score[0])
    print('Test accuracy:', score[1])

    # Save results
    suffix = file_utils.unique_filename('datetime')
    foldname = 'output_' + suffix
    os.makedirs(foldname)
    keras.save_history_history(
        'history_history.npy', history.history, fold=foldname)
    model.save_weights(os.path.join(foldname, 'dl_model.h5'))
    print('Output results are saved in', foldname)

    if fig:
        plt.figure(figsize=(12, 4))
        plt.subplot(1, 2, 1)
        keras.plot_acc(history)
        plt.subplot(1, 2, 2)
        keras.plot_loss(history)
        plt.show()

    self.history = history

    return foldname
```

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

④ 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

```
def run(self, epochs=100, batch_size=128, verbose=1):  
    data = self.data  
    model = self.model  
    fig = self.fig  
  
    history = self.fit(epochs=epochs,  
                      batch_size=batch_size, verbose=verbose)  
  
    score = model.evaluate(data.X_test, data.Y_test, verbose=0)  
  
    print('Confusion matrix')  
    Y_test_pred = model.predict(data.X_test, verbose=0)  
    y_test_pred = np.argmax(Y_test_pred, axis=1)  
    print(metrics.confusion_matrix(data.y_test, y_test_pred))  
  
    print('Test score:', score[0])  
    print('Test accuracy:', score[1])
```

- ✓ 성능 평가 전체를 진행하는 run()함수 구현
- ✓ 함수 내에서 학습과 성능 평가를 담당하는 history
- ✓ 오류 메트릭스

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

④ 분류 CNN의 학습 및 성능 평가를 위한 머신 클래스

```
# Save results
```

```
suffix = sfile.unique_filename('datetime')
```

```
foldname = 'output_' + suffix
```

```
os.makedirs(foldname)
```

```
skeras.save_history_history(  
    'history_history.npy', history.history, fold=foldname)
```

```
model.save_weights(os.path.join(foldname, 'dl_model.h5'))
```

```
print('Output results are saved in', foldname)
```

```
if fig:
```

```
    plt.figure(figsize=(12, 4))
```

```
    plt.subplot(1, 2, 1)
```

```
    skeras.plot_acc(history)
```

```
    plt.subplot(1, 2, 2)
```

```
    skeras.plot_loss(history)
```

```
    plt.show()
```

```
self.history = history
```

```
return foldname
```

- ✓ 현재 시각을 초 단위로 구해 새로운 이름 생성
- ✓ 새로운 저장용 폴더 생성
- ✓ History_history.npy에 저장
- ✓ 가중치는 dl_model.h5에 저장
- ✓ 저장 폴더가 겹치지 않기 위해 생성한 문자열 앞에 임의로 'output_' 붙임
- ✓ 학습 곡선 그리기

04. 2) 컬러 이미지를 분류하는 CNN 구현

- 구현 방법 및 단계

- ⑤ 분류 CNN의 학습 및 성능 평가 수행

```
# 5. 분류 CNN의 학습 및 성능 평가 수행
from keras import datasets
import keras
assert keras.backend.image_data_format() == 'channels_last'

# from keraspp import aicnn
class MyMachine(Machine):
    def __init__(self):
        (X, y), (x_test, y_test) = datasets.cifar10.load_data()
        super(MyMachine, self).__init__(X, y, nb_classes=10)

def main():
    m = MyMachine()
    m.run(epochs=2)

main()
```

- ✓ 분류 CNN을 위한 머신에 기반하여 이미지 분류
- ✓ Epochs 100으로 실행

실습 시-작 😊

